

Integridade de Dados e Reprodutibilidade Científica: As Inconsistências Históricas no Conjunto de Dados Iris

O conjunto de dados *Iris*, introduzido pelo estatístico Ronald A. Fisher (1936) e fundamentado nas coletas originais do botânico Edgar Anderson (1935), consolidou-se como o *benchmark* fundamental para o desenvolvimento de técnicas de classificação e análise discriminante linear. Devido à sua simplicidade e estrutura, o dataset tornou-se o padrão ouro para o ensino de Aprendizado de Máquina (*Machine Learning*). No entanto, a longevidade e a disseminação massiva deste conjunto em repositórios digitais — notadamente no UCI Machine Learning Repository — deram origem a um fenômeno de erosão de dados através de erros de transcrição manual (BEZDEK *et al.*, 1999).

As discrepâncias mais documentadas referem-se às amostras de índice 35 e 38 da classe *Iris-setosa*. Na versão digital amplamente difundida, o 35º exemplar foi registrado com largura de pétala de 0,1 cm, enquanto o artigo original de Fisher indica 0,2 cm (FISHER, 1936). De forma mais acentuada, a 38ª amostra sofreu uma alteração em dois atributos, onde valores de 3,6 cm (largura da sépala) e 1,4 cm (comprimento da pétala) foram indevidamente padronizados para 3,1 cm e 1,5 cm, respectivamente (BEZDEK *et al.*, 1999). Embora tais variações milimétricas possuam impacto estatístico marginal na maioria dos classificadores modernos, elas levantam questões críticas sobre a proveniência dos dados e a fidelidade das implementações computacionais em relação às publicações originais.

A correção desses pontos por bibliotecas líderes de mercado, como o Scikit-Learn (a partir da versão 0.20), reflete uma maturidade recente na área de Ciência de Dados, priorizando a reprodutibilidade exata (SCIKIT-LEARN, 2018). Cabe notar que, embora a biblioteca tenha sido academicamente apresentada por Pedregosa *et al.* (2011) com foco em arquitetura e performance, a retificação posterior do dataset demonstra o compromisso contínuo com a integridade científica. O episódio serve como uma lição epistemológica: a confiança cega em repositórios de dados pode perpetuar erros históricos. A análise cuidadosa da fonte primária permanece, portanto, um requisito indispensável para a prática científica rigorosa, garantindo que a modelagem estatística seja construída sobre uma base factual íntegra e não sobre artefatos de transcrição digital.

Referências Bibliográficas

- ANDERSON, E. The irises of the Gaspé Peninsula. **Bulletin of the American Iris Society**, v. 59, p. 2-5, 1935. DOI: 10.6084/m9.figshare.29614355.
- BEZDEK, J. C. *et al.* Will the real iris data please stand up? **IEEE Transactions on Fuzzy Systems**, v. 7, n. 3, p. 368-369, 1999. DOI: 10.1109/91.771092.
- FISHER, R. A. The use of multiple measurements in taxonomic problems. **Annals of Eugenics**, v. 7, n. 2, p. 179-188, 1936. DOI: 10.1111/j.1469-1809.1936.tb02137.x.

PEDREGOSA, F. *et al.* Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011. Disponível em: <http://jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 16 abr. 2026.

SCIKIT-LEARN. **What's new (Changelog): Version 0.20.0**. [S. l.], 2018. Disponível em: https://scikit-learn.org/stable/whats_new/v0.20.html#datasets. Acesso em: 16 abr. 2026.

SCIKIT-LEARN. **Issue #10550: Iris dataset inconsistency compared to other sources**. GitHub, 2018. Disponível em: <https://github.com/scikit-learn/scikit-learn/issues/10550>. Acesso em: 16 abr. 2026.

UCI MACHINE LEARNING REPOSITORY. **Iris Data Set**. [S. l.], [20--?]. Disponível em: <https://archive.ics.uci.edu/ml/datasets/iris>. Acesso em: 26 mar. 2026.